重要性采样 (Importance Sampling)

采样的一个重要目的是获得函数 $f(x)$ 在分布 $p(x)$ 上的期望值，即：$\mathbb{E}[f] = \int f(x)p(x)dx$。

通过对 $p(x)$ 采样可以得到近似值 $\mathbb{E}[f] \approx \frac{1}{L}\sum_{l=1}^{L} f(x^{(l)})$ 。

如果 $p(x)$ 不容易采样，一个替代方法就是对一个已知（容易）的分布 $q(x)$ 采样，然后根据 $p(x^{(l)})$ 和 $q(x^{(l)})$ 的比值调整每个样本的权重。

具体表达式是这样的：$\mathbb{E}[f] = \int f(x)p(x)dx = \int f(x)\frac{p(x)}{q(x)}q(x)dx \approx \frac{1}{L}\sum_{l=1}^{L}\frac{p(x^{(l)})}{q(x^{(l)})}f(x^{(l)})$，其中 L 个样本是从 $q(x)$ 采样得出的。

其中 $r^{(l)} = \frac{p(x^{(l)})}{q(x^{(l)})}$ 是权重，体现了样本的重要性。

对于分布 $p(x) = \frac{\tilde{p}(x)}{\int \tilde{p}(x)dx} = \frac{\tilde{p}(x)}{Z}$，如果 Z 未知，期望值这样计算：$\mathbb{E}[f] \approx \sum_{l=1}^{L} w_l f(x^{(l)})$，其中 $w_l = \frac{\tilde{p}(x^{(l)})/q(x^{(l)})}{\sum_m \tilde{p}(x^{(m)})/q(x^{(m)})}$ 。具体推导在最后。

例子

下面看看如何用重要性采样方法计算 $f(x) = \frac{x}{50}$ 在一个高斯混合分布 $\tilde{p}(x)$ 上的期望值，x 的取值范围是 $[0, 10]$。$\tilde{p}(x)$ 的具体定义是：
$\tilde{p}(x) = 0.3 * Normal(mean = 4, sd = 1) + 0.7 * Normal(mean = 7, sd = 0.5)$。

这里用到的 $q(x)$ 是 $Normal(mean = 5, sd = 2)$。

图示如下：

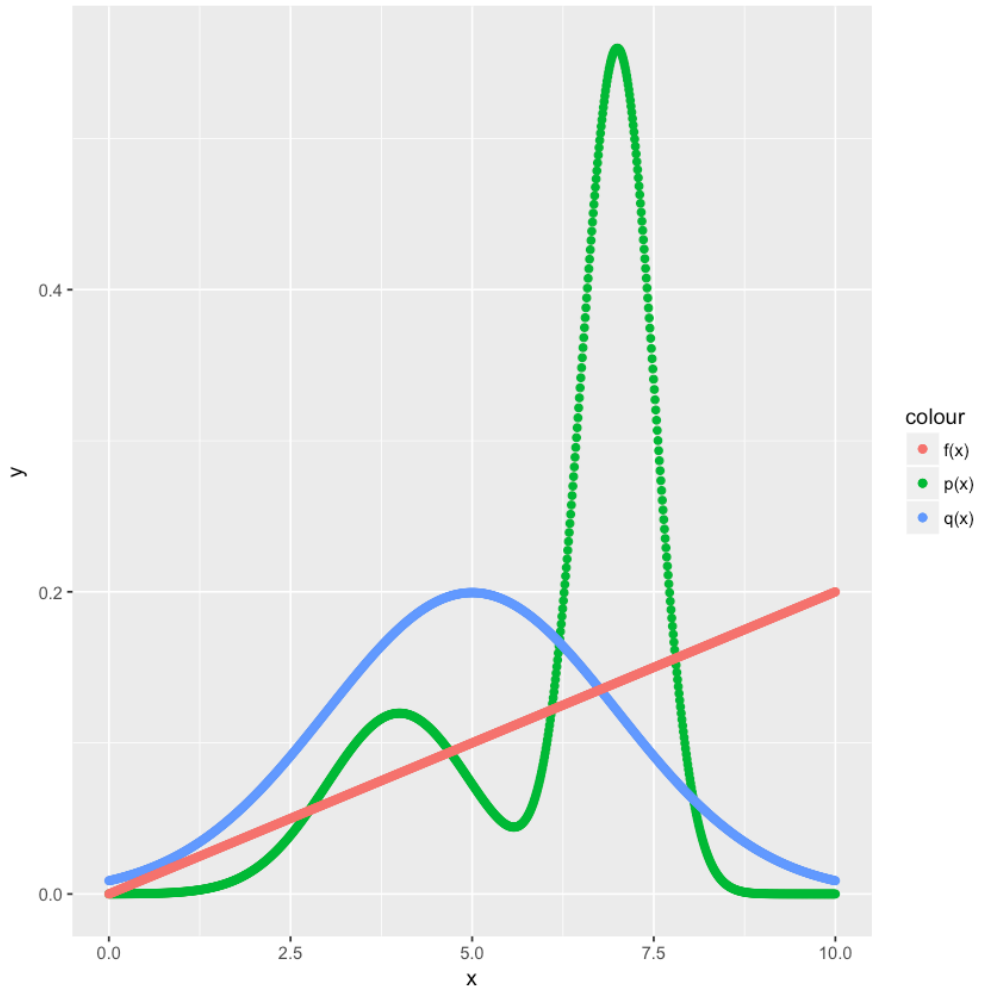

对于直线 $f(x) = \frac{x}{50}$，如果 x 是均匀分布，则在 $[0, 10]$ 的范围内，x 的期望值是平均值 0.1。但 $p(x)$ 在靠近 7 的位置密度较大，那相对与 $p(x)$ 的期望值估计要大于 0.1。

下面具体计算一下：

In [4]:
```
ptilde = function(x) {
    p = 0.3 * dnorm(x, mean=4, sd=1) + 0.7 * dnorm(x, mean=7, sd=0.5)
    return(p)
}

fx = function(x) {
    return(x/50)
}

n=10000
sample.x = rnorm(n, mean=5, sd=2)
r.l = ptilde(sample.x) / dnorm(sample.x, mean=5, sd=2)
w.l = r.l/sum(r.l)
exp.x = sum(w.l * fx(sample.x))
exp.x
```

0.122001413650187

确实大于 0.1，但是如何确定这个值是正确的呢?

下面用 Accept-Reject Sampling 方法从 $p(x)$ 中采样，然后估算 $f(x)$ 的期望值。

接受/拒绝采样中的提议分布 (proposal distribution) 是 $Normal(mean = 7, sd = 2)$。图示如下:

In [7]:
```
library(ggplot2)
x=seq(0,10,length=1000)
df = data.frame(x=x, y=ptilde(x), norm=3*dnorm(x, mean=7, sd=2))
ggplot(df, color=variable)+geom_point(aes(x,y, col='y'))+geom_point(aes(x,y=norm, co
l='norm'))
```

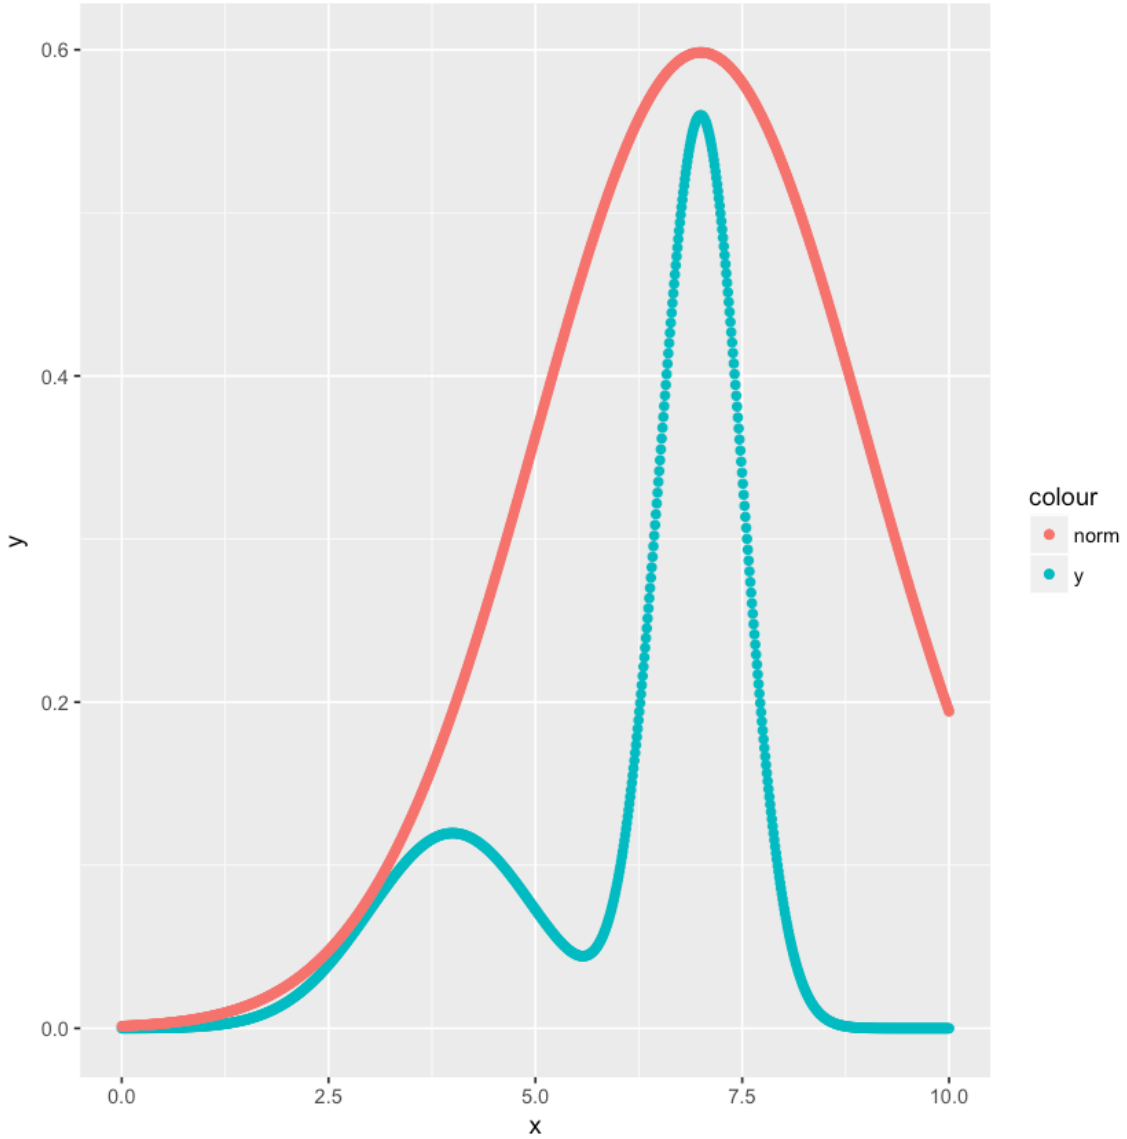

接受/拒绝的采样过程:

In [17]:
```
n=50000
zs=c()
us=c()
for (i in seq(0,1,length=n)) {
    zi = rnorm(1, mean=7, sd=2)
    q  = 3 * dnorm(zi, mean=7, sd=2)
    u  = runif(1, min=0, max=q)
    if (u > ptilde(zi))
        next
    zs = append(zs, zi)
    us = append(us, u)
}
length(zs)
```

16798

采样的结果，直方图：

In [22]:
```
ggplot(data.frame(x=zs), color=variable) + geom_histogram(mapping=aes(x, col='histog
ram'), binwidth=0.05)
```

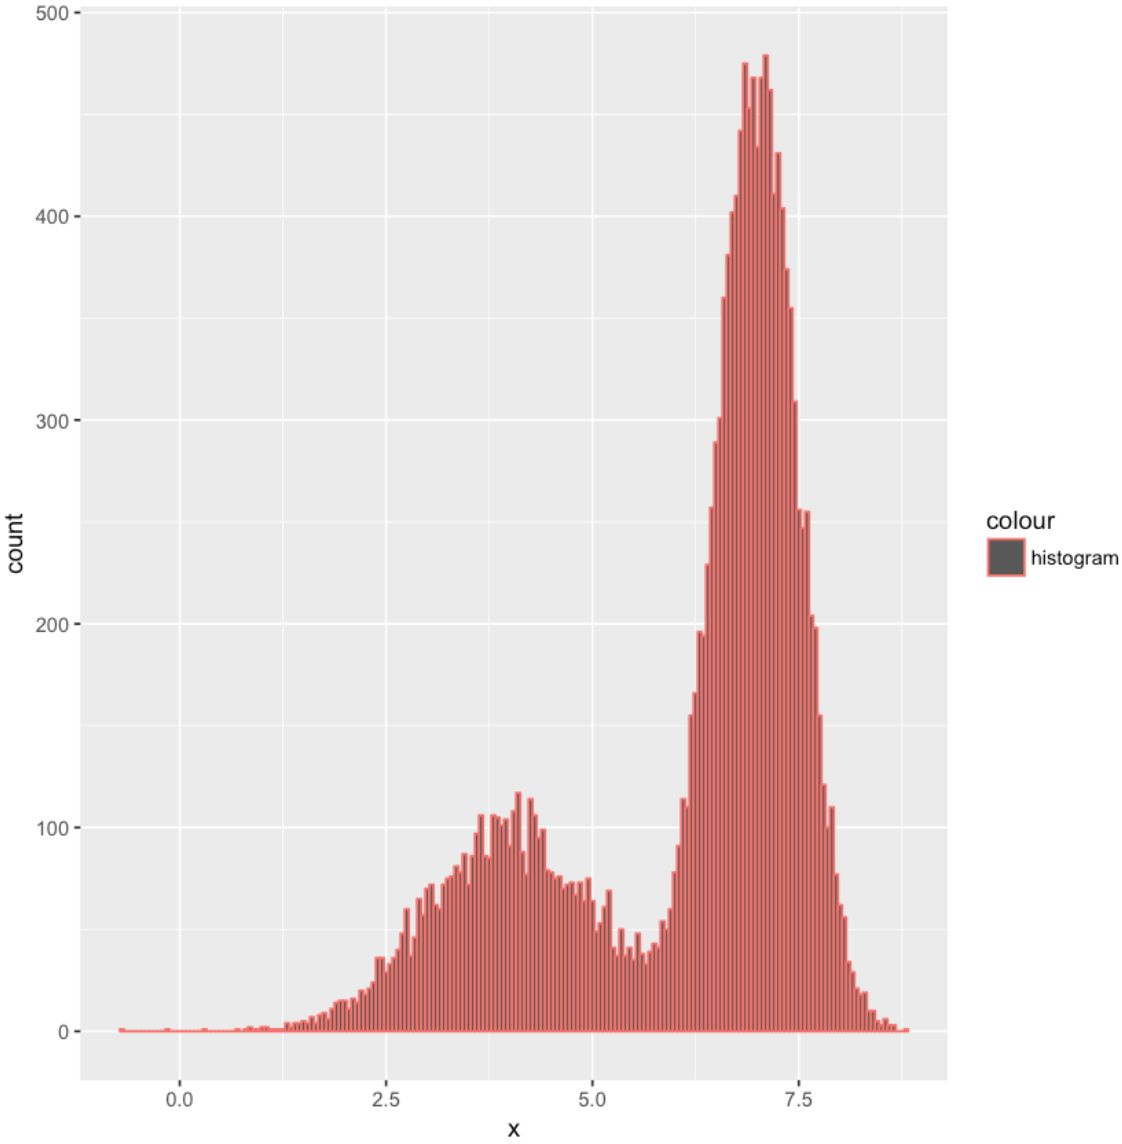

可以看出是大致符合上面定义的高斯混合分布。

下面针对这些样本计算 $f(x)$ 的期望值：

In [18]:
```
sum(fx(zs))/length(zs)
```

0.122138622373852

与上面通过 Importance Sampling 计算出的值基本吻合。

重要性重采样

上面针对 $p(x)$ 计算了 $f(x)$ 的期望值，但是这个方法也可以用来对 $p(x)$ 采样。

步骤是：

1. 从 q(x) 采样 L 个样本
2. 计算每个样本的权重 w_l （计算方法见上一节）
3. 根据权重 w_l 再从上面的 L 个样本中采样出 L 个样本（当然有重复）

最后得出的 L 个样本将符合 $p(x)$ 分布。由于最后一步从已有的样本中采样，所以叫重采样。

下面看看效果。

In [25]:
```
df = data.frame(x=sample(sample.x, length(sample.x), replace=T, prob=w.l))
ggplot(df, color=variable)+geom_histogram(aes(x, col='sample'), binwidth=0.05)
```

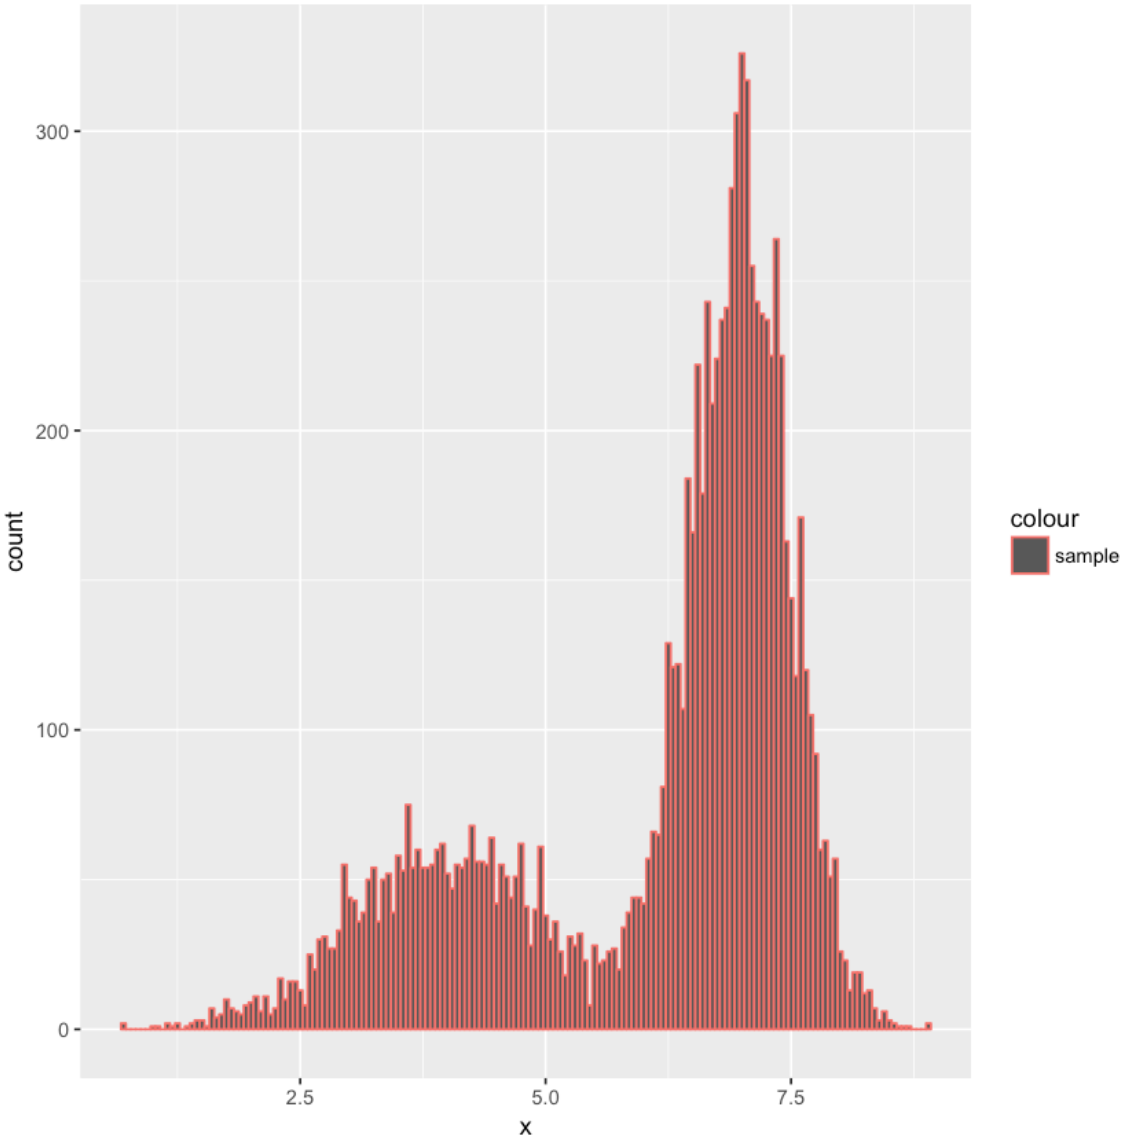

也是大致符合目标分布。

权重计算公式的推导

参考自 PRML (https://www.amazon.com/Pattern-Recognition-Learning-Information-Statistics/dp/0387310738) 11.1.5。

设 $p(x) = \frac{\tilde{p}(x)}{Z_p}$ 和 $q(x) = \frac{\tilde{q}(x)}{Z_q}$。

$$\mathbb{E}[f] = \int f(x)p(x)dx = \frac{Z_q}{Z_p}\int f(x)\frac{\tilde{p}(x)}{\tilde{q}(x)}q(x)dx \approx \frac{Z_q}{Z_p}\frac{1}{L}\sum_{l=1}^{L}\tilde{r}_l f(x^{(l)})$$

其中，$\tilde{r}_l = \frac{\tilde{p}(x^{(l)})}{\tilde{q}(x^{(l)})}$ 。

$$\frac{Z_p}{Z_q} = \frac{1}{Z_q}\int \tilde{p}(x)dx = \int \frac{\tilde{p}(x)}{\tilde{q}(x)}q(x)dx \approx \frac{1}{L}\sum_{l=1}^{L}\tilde{r}_l$$

$$\frac{Z_q}{Z_p} = L \times \frac{1}{\sum_{l=1}^{L}\tilde{r}_l}$$

带入期望值的公式：$\mathbb{E}[f] \approx \sum_{l=1}^{L}\frac{\tilde{r}_l}{\sum_m \tilde{r}_m}f(x^{(l)}) = \sum_{l=1}^{L} w_l f(x^{(l)})$。

其中 $w_l = \frac{\tilde{r}_l}{\sum_m \tilde{r}_m} = \frac{\tilde{p}(x^{(l)})/q(x^{(l)})}{\sum_m \tilde{p}(x^{(m)})/q(x^{(m)})}$ （Z_q可以被消掉）。

其他

重要性采样在图模型（Graph Model）中有较多应用，以后在碰到图模型的时候再讨论。